Web Scraping: Mubawab.ma

!apt-get update !apt install chromium-chromedriver

install chromium, its driver, and selenium !pip install selenium # set options to be headless, ...

wd = webdriver.Chrome('chromedriver', options=options)

wd.get("https://www.mubawab.ma/fr/plr/casablanca-settat/listing-promotion")

n_elems = len(wd.find_elements_by_xpath('//*[@id="listingUl"]/li'))

prix = wd.find element by xpath(f'//*[@id="listingUl"]/li[{i+1}]/div[2]/span') #Locate the price

standings

Haut standing, Finalisé

Moyen standing, Finalisé

Haut standing, Finalisé

Haut standing, Finalisé

Haut standing, Finalisé

Haut standing, Finalisé

Moyen standing, Finalisé

Haut standing, Finalisé

Moyen standing, Finalisé

Haut standing, Finalisé

Haut standing, Finalisé

Finalisé

Haut standing, En cours de construction

Moyen standing, En cours de construction Haut standing, En cours de construction

Haut standing, En cours de construction

Haut standing, En cours de construction

Les Jardins de Ain Sebâa lance sa de... Moyen standing, En cours de construction 2227 Publié il y a plus de 6 mois

ids

2621

2854

2925

2734

3294

3221

3357

2928

1729

3262

3241

2254

1730

474

3512

2772

863

2927

2716

3274

3364

3446

2585

3517

3429

1732

2563

3289

3479

dates

Publié il y a plus de 6 mois

Publié il y a 5 mois

Publié il y a 3 mois

Publié il y a 1 mois

Publié il y a 3 mois

Publié il y a 2 mois

Publié il y a 2 mois

from selenium import webdriver options = webdriver.ChromeOptions() options.add argument('--headless') options.add argument('--no-sandbox') options.add argument('--disable-dev-shm-usage') import numpy as np import pandas as pd

open it, go to a website, and get results

Get the city's number districts to navigate

Get Prices, quartiers, Standing, IDs and Dates

print(wd.page source) # results

url ard = wd.current url

n elems

prices = [] quartiers = [] standings = [] ids = []dates = []

price

In [4]:

In [4]:

!cp /usr/lib/chromium-browser/chromedriver /usr/bin

prix text = prix.text #Get the price value # print(prix text) prices.append(prix_text) # quartier

for i in range(n elems):

quartier = wd.find element by xpath(f'//*[@id="listingUl"]/li[{i+1}]/div[2]/h2/a') #Locate the nq'th neight qrt text = quartier.text #Get the neighbourhood name # print(qrt text) quartiers.append(qrt_text) # standing

standing = wd.find element by xpath(f'//*[@id="listingUl"]/li[{i+1}]/div[2]/div[1]/h4') #Locate the nq'th standing text = standing.text #Get the standing text name # print(standing text) standings.append(standing_text) # id annonceur id annonceur = wd.find element by xpath(f'//*[@id="listingUl"]/li[{i+1}]') promotion id = id annonceur.get attribute("promotion-id")

date livraison text = date livraison.text

df.columns = ['prices', 'quartiers', 'standings', 'ids', 'dates']

quartiers

Central Park

Atlantic Eden

QUEENS

Sea View

Rosa Parc Magasins

Fdala Business Center

Bouskoura Golf City

Les Perles Ain Sebaâ

Casabay Sidi Rahal

Evasion Bouznika

Résidence DIAZ

Résidence Jacinth

Résidence Les Jasmins I

Vert Marine - Triplex

Zenata Tower

LIV'IN Garden

Famille D'amour

df = pd.concat([pd.DataFrame(lst) for lst in all_data], axis=1).reset_index(drop = True)

ids

2621

2854

2925

2734

3294

3221

2928

3262

3241

2254

1730

474

2927

2716

3274

3364

3446

2585

3517

3429

1732

2563

3289

3479

2227

dates

Publié il y a plus

de 6 mois

mois

mois

mois

mois

Publié il y a 5

Publié il y a 3

Publié il y a plus

de 6 mois

Publié il y a 1

Publié il y a 3

Publié il y a plus

Publié il y a plus

Publié il y a plus

de 6 mois

de 6 mois

de 6 mois

de 6 mois

mois

Publié il y a 2

Publié il y a plus

mois

Publié il y a 2

lats

33.70259958074599

33.51788561426908

33.57905668978428

33.57340232956212

33.53037726442764

33.54574410154525

33.52996746536189

33.703081563375555

33.613046760187586

33.65439484793648

33.708775894156645

33.51741153987773

33.612153263231825

33.468909499547884

33.525617486869486

33.47727218776036

33.613904508551194

33.79291733259281

33.82720675529752

33.57851904580247

33.57204358621036

33.61252853308126

33.6115456800117

33.703081563375555

33.612153263231825

33.57905668978428

longs

-7.399420738220243

-7.795518636703463

-7.647800104393838

-7.478427886963118

-7.8294328124397055

-7.739739418029757

-7.829604148864917

-7.391266822814885

-7.128281593322384

-7.477188643157888

-7.397832870483342

-7.819862365722656

-7.128067016601619

-7.605187939053451

-7.779886722564612

-7.9520416259765625

-7.537994384765739

-7.159635275602341

-7.1224145045069065

-7.643845358811291

-7.4776983261109535

-7.128324508666964

-7.535612583160315

-7.391266822814885

-7.128067016601619

-7.647800104393838

standings

Haut standing, Finalisé

Moyen standing, Finalisé

Haut standing, Finalisé

de construction

construction

construction

construction

de construction

Moyen standing, En cours

Haut standing, En cours de

Haut standing, En cours de

Moyen standing, Finalisé

Haut standing, Finalisé

Haut standing, Finalisé

Moyen standing, En cours

Haut standing, En cours de

Haut standing, Finalisé

construction

construction

construction

Finalisé

Haut standing, En cours de

Haut standing, En cours de

df.columns = ['prices','quartiers','standings','ids','dates','lats','longs']

quartiers

Central Park

QUEENS

Next House Zenata Eco City

Les Allées de Californie lance sa 2è...

Ahl Loghlam - Moyen standing-Tit Mel...

Joyau du Parc Magasins

Ocean Park

Villas des Prés

Vert Marine 3

Show results in DataFrame all data = [prices , quartiers , standings , ids , dates] df = pd.concat([pd.DataFrame(lst) for lst in all data] , axis=1).reset index(drop = True) #Set the dataframe's columns

print(date_livraison_text) dates.append(date livraison text)

print(promotion id) ids.append(promotion_id)

date livraison

0 À partir de 773 000 DH À partir de 2 800 000 DH À partir de 1 233 000 DH

prices

Ahl Loghlam- Lots de terrain À partir de 1 600 000 DH 4 5 À partir de 726 000 DH Résidence Assafoi - Terrains et loca...

Duplex 3 chambres Front Mer 7 À partir de 720 000 DH 8 À partir de 540 000 DH Shems Al Madina - Lots de terrain

10 À partir de 978 500 DH À partir de 3 500 000 DH Shems Al Madina - Lots de Villas

14 15 16 À partir de 848 000 DH 17

À partir de 1 000 000 DH 20 21 À partir de 823 000 DH 22 À partir de 820 000 DH

À partir de 1 070 000 DH 25 Prix à consulter 26 À partir de 519 303 DH À partir de 770 000 DH

Get Latitude, Longitude and concatenate all columns lats = []

longs = []

import time

wd.get(url ard) #Go back to last page page_list = wd.find_element_by_xpath(f'//*[@id="listingUl"]/li[{j+1}]') #Locate the price page list.click() time.sleep(t) mapOpen = wd.find element by id('mapOpen')

time.sleep(t) all_data = [prices , quartiers , standings , ids , dates , lats , longs]

#Set the dataframe's columns

lat = mapOpen.get_attribute("lat")

À partir de 1 4 Sea View

Résidence Assafoi -5 000 DH Terrains et loca... À partir de 2 **Duplex 3 chambres Front** 6 900 000 DH

7 000 DH À partir de 540 000 DH

À partir de 519 000 DH À partir de 978 500 DH

À partir de 3 500 000 DH 000 DH À partir de 2 200 000 DH

À partir de 1 600 000 DH 000 DH 000 DH

Atlantic Eden 800 000 DH À partir de 1 233 000 DH Ahl Loghlam- Lots de Prix à consulter 600 000 DH

prices

000 DH

À partir de 773

À partir de 2

À partir de 720 Rosa Parc Magasins

de terrain Ocean Park Fdala Business Center

Villas des Prés À partir de 475 Shems Al Madina - Lots de Villas Bouskoura Golf City

Vert Marine 3

À partir de 880 Les Perles Ain Sebaâ

A partir de 890 Casabay Sidi Rahal

À partir de 726

Shems Al Madina - Lots

Haut standing, En cours de

Joyau du Parc Magasins

À partir de 848

000 DH À partir de 1

Evasion Bouznika 850 000 DH À partir de 860 Résidence DIAZ 000 DH À partir de 1 Résidence Jacinth

Résidence Les Jasmins I

Next House Zenata Eco

Vert Marine - Triplex

Les Allées de Californie

Ahl Loghlam - Moyen

standing-Tit Mel...

lance sa 2è...

Zenata Tower

LIV'IN Garden

Famille D'amour 28 Prix à consulter À partir de 716 Les Jardins de Ain Sebâa 29 000 DH lance sa de... Save Data in xlsx file

À partir de 820

À partir de 3

980 000 DH

À partir de 1 070

Prix à consulter

À partir de 519

À partir de 770

000 DH

000 DH

303 DH

000 DH

3 Prix à consulter

À partir de 2 900 000 DH 9 À partir de 519 000 DH

À partir de 475 000 DH 12 13 À partir de 2 200 000 DH À partir de 1 600 000 DH À partir de 880 000 DH À partir de 890 000 DH

À partir de 1850 000 DH 18 19 À partir de 860 000 DH À partir de 3 980 000 DH 24

27 28 Prix à consulter 29 À partir de 716 000 DH

t = 5for j in range(n_elems): # long and lat

lon = mapOpen.get attribute("lon") lats.append(lat) longs.append(lon) # wd.execute script("window.history.go(-1)") wd.back()

Show all results in a Dataframe In [9]: df

0

1

2

15

22

23

25

26

27

df.to excel(r'mubawab data.xlsx', index = False)

Haut standing, En cours de construction Publié il y a plus Moyen standing, Finalisé Publie il y a plus Haut standing, Finalisé 863

> 33.547117579470296 -7.675495147705078 33.70650177897868 -7.3963093757629395 -7.757291793823242 33.5201665019058 33.61040882133904 -7.480355685654416